

World Of Tech 2017

2017年4月14日-15日 北京富力万丽酒店

RHIECOX





出品人及主持人:

海滴出行基础平台部 技术总监

创新运维探索



基于Mesos/Docker构建企业级SaaS应用 —— Elasticsearch as a Service

马文 去哪儿网opsdev







马文

去哪儿网

平台事业部数据平台研发工程师

分享主题:

基于Mesos/Docker构建 Elasticsearch as a Service



主要内容:

- 背景/设计目标 技术调研/选型 细节实现 集群信息汇总与自助配置 自动化部署 监控与报警 日志/marathon事件收集

- 问题&解决





背景/设计目标

Elasticsearch需求量暴增带来的交付与维护弊端:

- 传统部署以kvm虚机或实体机为ES节点,需要提前创建虚拟机或申请实体机
- ES运行环境需使用ansible, salt等工具事先部署
- 节点扩容需人力一遍一遍去部署环境
- 集群不易于管理,维护成本高





背景/设计目标

针对上述弊端, 我们制定的几点设计目标:

- 加快集群构建速度
- 快速扩容和快速迁移能力
- ES使用/运维标准化
- 集中的信息展示与良好的用户交互界面





背景/设计目标

容器化的私有云平台 Elasticsearch as a service (ESAAS)





技术调研

- Elastic Cloud
 - Elastic官方的公有云平台,能够做到ES服务即启即用,横向扩容,自助配置等
- Amazon Elasticsearch Service
 - 基于亚马逊AWS公有云服务的搜索和分析平台, 同Elastic cloud一样,能够提供即启即用的ES服务
- Elasticsearch Framework on Mesos
 - 一个开源的基于Mesos的任务调度框架,每一个executor即为一个ES节点实例,每一个框架即为一个ES集群。功能少,无法配置多角色的节点, 无法提供插件,script等自定义配置等





预期功能点

- 集群统一管理/集中的信息交付
- 集群资源quota限定/集群隔离
- 数据持久化存储/可靠性保障
- 数据节点快速水平/垂直扩容
- 集群/外围插件/script的自助配置
- 集群的发布和配置管理
- 完整的集群/平台监控和报警





技术选型











总体结构

Elasticsearch bamboo dashboar	es2graphite •••••
Docker	
Elasticsearch Saas	
Sub-Marathon Sub-Marathon	Sub-Marathon • • • • •
Marathon	
Mesos	
Node Node Node	le Node Node





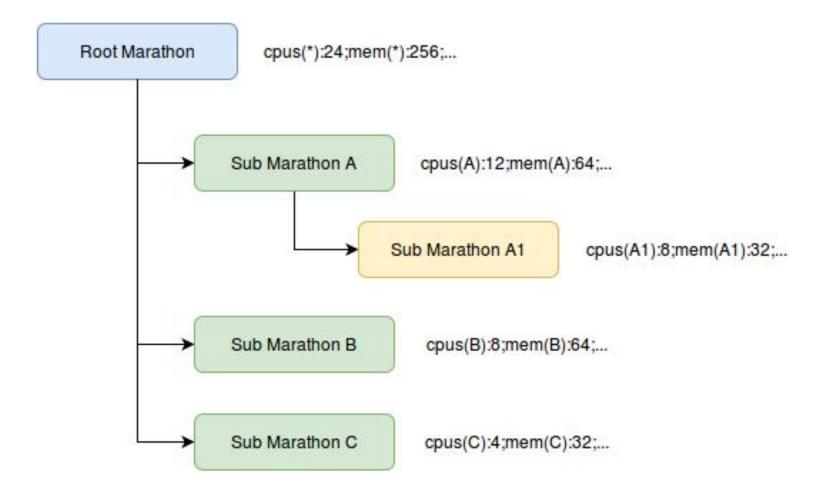
几个核心问题

- Quota分配
- 集群的隔离
- 服务发现
- •数据可靠性
- 自助化集群配置
- 集中的交付信息展示
- 部署自动化
- 监控与报警





资源分配结构







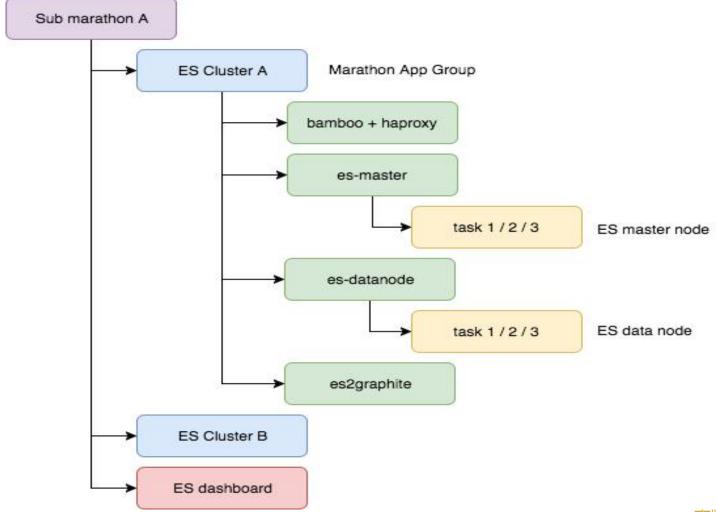
Quota & 资源划定

- Mesos Role & 动态Quota设定
- Root marathon 不做资源设定, 拥有系统全部的资源
- •每一个Sub-marathon都拥有不同的Role
- 自由Sub-marathon享有限定范围内的资源, 并具有逻辑上隔离的 命名空间





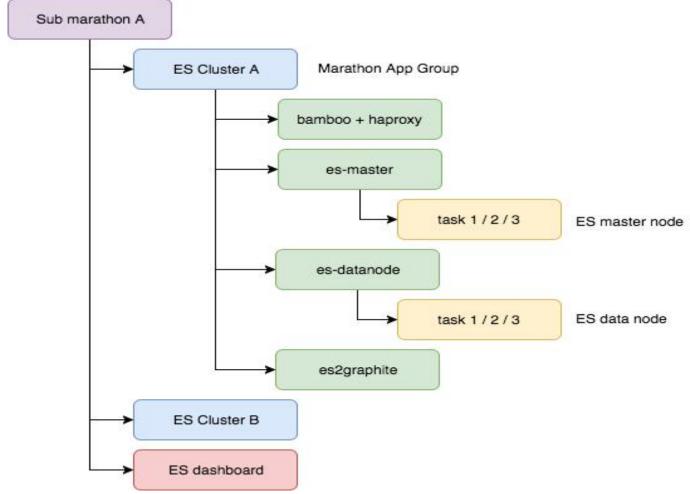
集群逻辑隔离/划分







集群逻辑隔离/划分

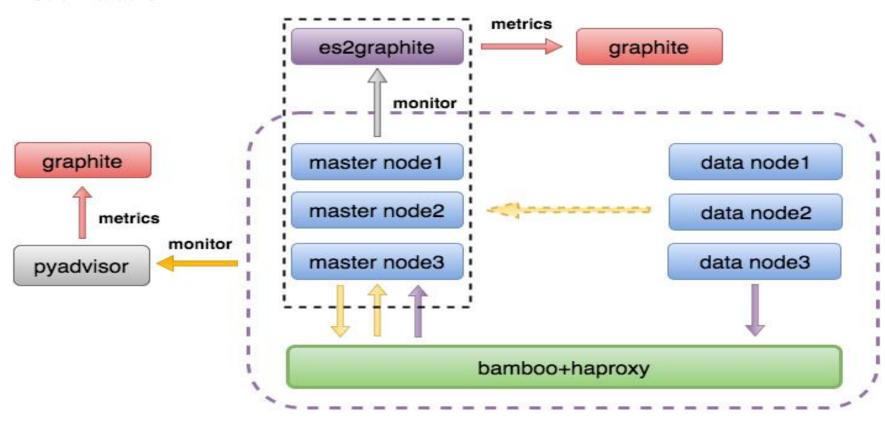






一个完整的ES集群逻辑结构

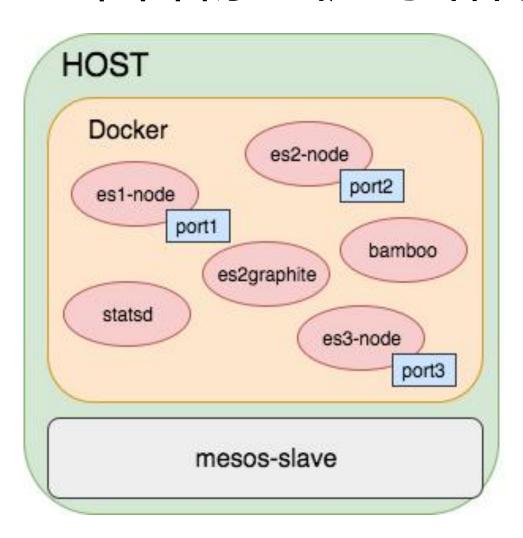
Sub-Marathon







单台物理机的结构



- 一个机器上可有多个ES 节点
- 使用不同的端口来区别ES集群



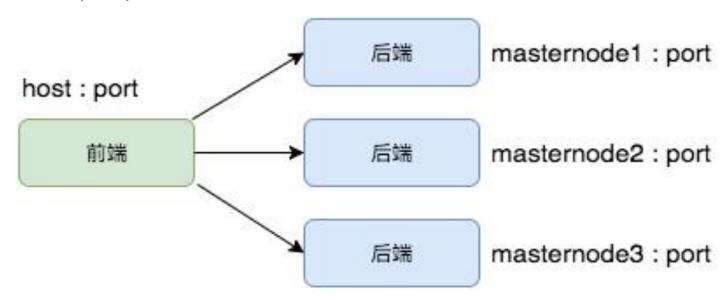


服务发现

使用bamboo + haproxy来实现ES集群内部节点发现:

• bamboo 是一个开源的marathon服务发现工具,通过注册marathon callback来监听marathon事件, 根据配置自动reload haproxy

bamboo + haproxy 内部端口转发示意图:

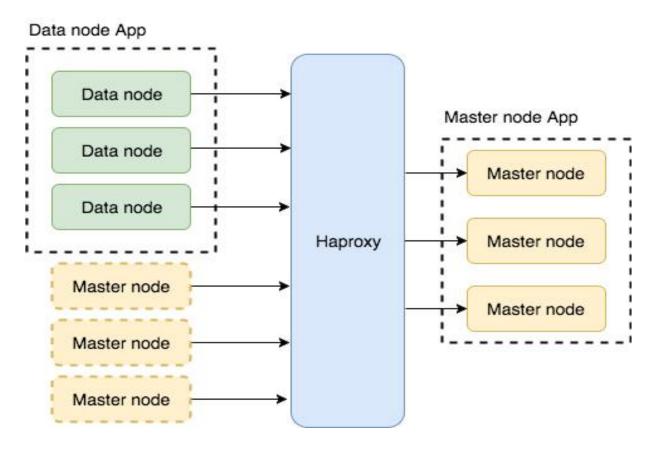






如何解决服务发现

discovery.zen.ping.unicast.hosts: ["<haproxy_ip>:<haproxy:port>"]







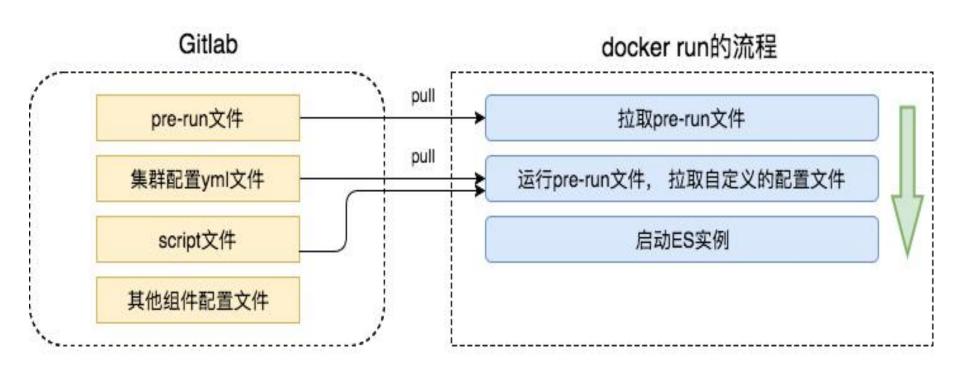
数据可靠性 & 持久化

- Marathon 持久化卷功能, 保证ES节点重启之后能在原机器节点 之上restart
- ES 每个索引至少有一个备份(index.number_of_replicas>=1)
- •默认配备hdfs插件,可将数据备份到hdfs上
- 每个宿主(mesos slave)上,同一ES集群的节点数不超过索引备份数 (防止主备分片被分配在同一台机器上面)





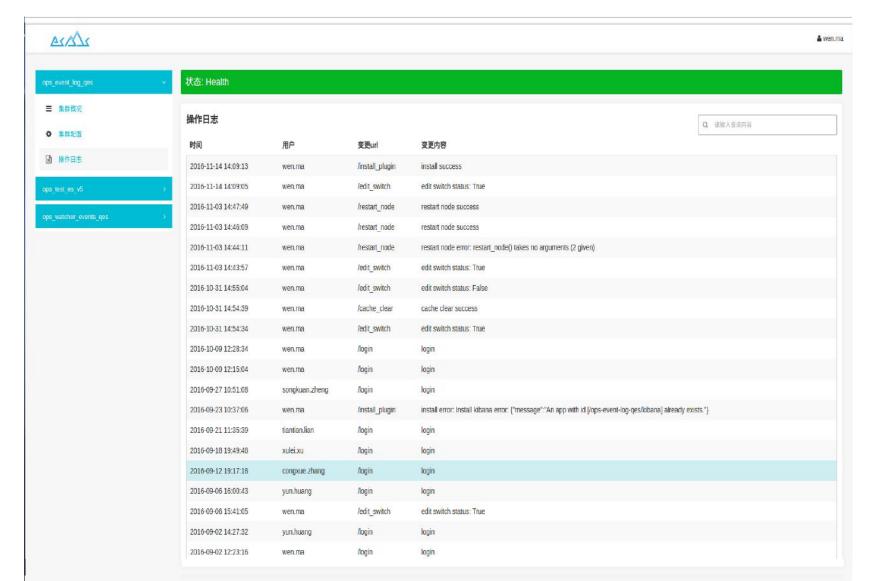
自助化配置





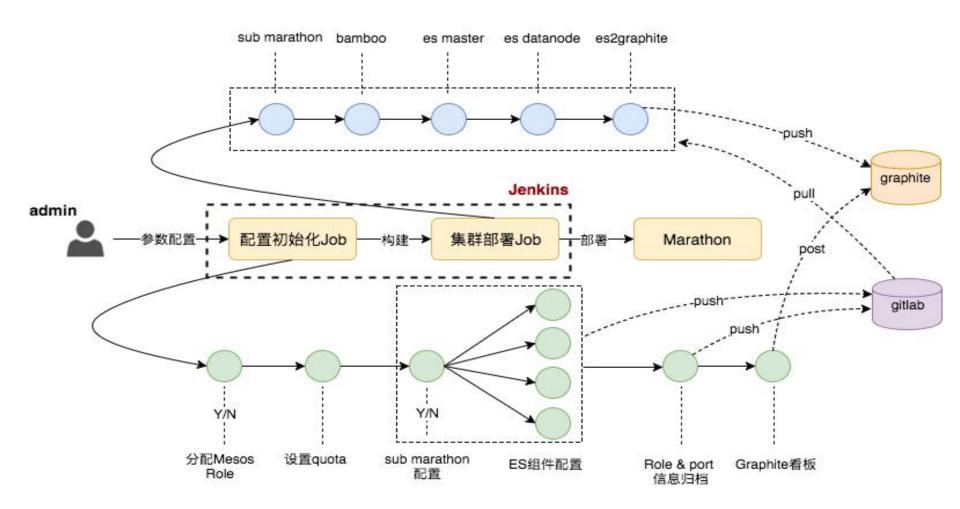


集群信息展示&配置





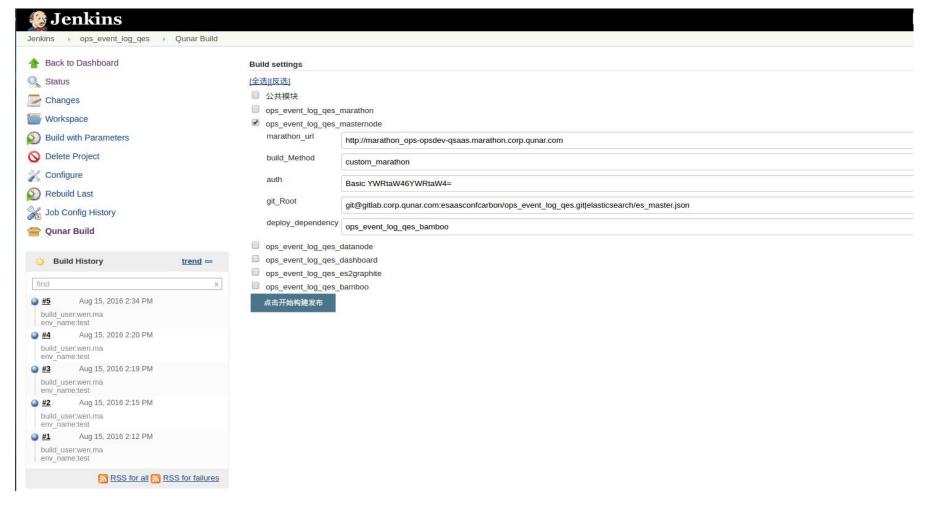
自动化部署







定制的Jenkins







监控与报警

- pyadvisor 收集docker 容器的指标
- es2graphite 收集ES集群的指标





指标聚合汇总





报警设置

- ES集群
 - ES集群状态(非green状态)
 - ES节点GC时间
 - 节点数量
- ESAAS平台
 - ZK相关
 - 节点load
 - 节点磁盘容量





日志/事件收集

平台日志分为两个部分:

- 1. Mesos日志 flume + kafka + logstash + elasticsearch + kibana
- 1. ES日志 filebeat + kafka + logstash + elasticsearch + kibana

Marathon事件收集:

1. nodejs 收集客户端 + kafka + logstash + elasticsearch + kibana





开发中的问题

- Mesos slave重启之后原有task不会原地恢复
 - Slave id会改变, mesos认为是新的slave
 - boot_id 标识机器是否重启
- Mararhon (1.1.1) 持久化卷bug
 - 宿主持久化目录mount错误
 - 持久化目录不能自定义
 - 只使用持久化特性, 自行挂载数据卷作为持久化卷
- 使用持久化卷特性,mesos slave只能root启动
 - 需要mount数据卷
 - ES/marathon 使用非root用户启动





运维中的问题

- 局部资源过热
 - I/O, load, 磁盘
 - 统计分析,标准差来衡量,平衡遵从原则:先手动后自动
- ES的JVM内存
 - 内存管理不是很好, 5.X之前CMS, 之后G1
 - 做好监控&报警,做好规划, 及时扩容
 - Query/Filter Cache
 - Fielddata Cache
 - Index Buffer
 - segment是JVM old memory消耗的主要者
 - 与数据量成正比,定期Force merge (索引越大越不明显)
 - Index.max_result_window, size巨大可导致内存被打爆





平台规模

- 平台机器数量: 87台服务器
- datanode数据节点机器数量: 79台服务器
- 当前托管的集群数量: 48个
- 当前可存储数据总量: 200TB左右
- 当前覆盖业务线: 30个
- 最大的集群数据量: ~50 T







